## Basic String Algorithms

ynycoding

2025年7月31日



# KMP 算法

有问题就讲讲

# EXKMP 算法

有问题就讲讲



## BZOJ4974 字符串大师

#### 题面

有一个未知字符串 s,定义 p[i] 为前缀  $s[1\cdots i]$  的 period,输入字符串长度 n 和数组 p,求出可能的 s 中字典序最小的一个。保证有解。  $n \leq 10^5$  。



## BZOJ4974 字符串大师

#### 题面

有一个未知字符串 s,定义 p[i] 为前缀  $s[1\cdots i]$  的 period,输入字符串长度 n 和数组 p,求出可能的 s 中字典序最小的一个。保证有解。  $n \leq 10^5$ 。

模拟 kmp,每次会知道字符的相等或者不等关系。直接贪心即可。



### LOJ 10035

### 题面

给定若干个长度  $\leq 10^6$  的字符串,询问每个字符串最多是由多少个相同的子字符串重复连接而成的。如:ababab 则最多有 3 个 ab 连接而成。  $n < 10^6$  。

### LOJ 10035

### 题面

给定若干个长度  $\leq 10^6$  的字符串,询问每个字符串最多是由多少个相同的子字符串重复连接而成的。如:ababab 则最多有 3 个 ab 连接而成。  $n \leq 10^6$  。

过于简单



# [NOI2014] 动物园

### 题面

对于字符串 S 的每个前缀,计算出它有多少个 border,满足这些 border 的长度都不超过该前缀长度的一半。

$$n \le 10^6$$
 o

## [NOI2014] 动物园

### 题面

对于字符串 S 的每个前缀,计算出它有多少个 border,满足这些 border 的长度都不超过该前缀长度的一半。

 $n \leq 10^6$  o

维护指针指向不超过一半长度的串。



# [NOIP2020] 字符串匹配

#### 题面

小C学习完了字符串匹配的相关内容,现在他正在做一道习题。

对于一个字符串 S,题目要求他找到 S 的所有具有下列形式的拆分方案数:

S = ABC, S = ABABC,  $S = ABAB \cdots ABC$ , 其中 A, B, C 均是非空字符串,且 A 中出现奇数次的字符数量不超过 C 中出现奇数次的字符数量。

更具体地,我们可以定义 AB 表示两个字符串 A,B 相连接,例如  $A=\mathsf{aab}$ ,

 $B=\mathsf{ab}$ ,则  $AB=\mathsf{aabab}$ 。

并递归地定义  $A^1=A$ ,  $A^n=A^{n-1}A$  ( $n\geq 2$  且为正整数)。例如  $A=\mathsf{abb}$ ,则  $A^3=\mathsf{abbabbabb}$ 。

则小 C 的习题是求  $S=(AB)^iC$  的方案数,其中  $F(A) \leq F(C)$ ,F(S) 表示字符串 S 中出现奇数次的字符的数量。两种方案不同当且仅当拆分出的  $A \times B \times C$  中有至少一个字符串不同。

小 C 并不会做这道题,只好向你求助,请你帮帮他。  $n \leq 10^7$  。

# [NOIP2020] 字符串匹配

枚举循环节 AB,利用 EXKMP 找到最大循环次数。利用桶和指针可以做到 O(n)。



## Trie

相信大家都会

### LOJ537

### 题面

现在给出一段 DNA 序列,请帮他求出这段 DNA 序列中所有连续 k 个碱基形成的 碱基序列中,出现最多的一种的出现次数。

$$n \le 5 \times 10^6, k \le 10 \circ$$

过于简单

# AC 自动机

有问题就讲讲

### LOJ10059

#### 题面

有一个长度不超过  $10^5$  的字符串 S。 Farmer John 希望在 S 中删掉 n 个屏蔽词(一个屏蔽词可能出现多次),这些词记为  $t_1 \sim t_n$ 。 FJ 在 S 中从头开始寻找屏蔽词,一旦找到一个屏蔽词,FJ 就删除它,然后又从头开始寻找(而不是接着往下找)。FJ 会重复这一过程,直到 S 中没有屏蔽词为止。注意删除一个单词后可能会导致 S 中出现另一个屏蔽词。这 n 个屏蔽词不会出现一个单词是另一个单词子串的情况,这意味着每个屏蔽词在 S 中出现的开始位置是互不相同的,请帮助 FJ 完成这些操作并输出最后的 S。  $n \leq 10^6$ 。

### LOJ10059

#### 题面

有一个长度不超过  $10^5$  的字符串 S。 Farmer John 希望在 S 中删掉 n 个屏蔽词(一个屏蔽词可能出现多次),这些词记为  $t_1 \sim t_n$ 。 FJ 在 S 中从头开始寻找屏蔽词,一旦找到一个屏蔽词,FJ 就删除它,然后又从头开始寻找(而不是接着往下找)。FJ 会重复这一过程,直到 S 中没有屏蔽词为止。注意删除一个单词后可能会导致 S 中出现另一个屏蔽词。这 n 个屏蔽词不会出现一个单词是另一个单词子串的情况,这意味着每个屏蔽词在 S 中出现的开始位置是互不相同的,请帮助 FJ 完成这些操作并输出最后的 S。  $n \leq 10^6$ 。

AC 自动机板子题

## Luogu2414

### 题面

输入一棵 Trie, 其上有 n 个单词结点, m 组询问, 每次询问第 x 个单词在第 y 个单 词中出现了几次。

$$n \leq 2 \times 10^5$$
 o

## Luogu2414

#### 题面

输入一棵 Trie,其上有 n 个单词结点,m 组询问,每次询问第 x 个单词在第 y 个单词中出现了几次。  $n < 2 \times 10^5$ 。

询问离线。每次枚举 y,对于 x 使用树状数组维护祖先的关键点个数。



## ARC141F

题面



### ARC141F

#### 题面

首先假设是合法的,那么对于每个串可以利用 AC 自动机贪心地删除。如果无法删除完则非法。

如果一个串有两种删法,那么一定有字符串相交。只需要判断是否存在除了相交的部分其余部分不相等的串。



## Manacher

有问题就讲讲

## Luogu4555

#### 题面

顺序和逆序读起来完全一样的串叫做回文串。比如 acbca 是回文串,而 abc 不是: abc 的顺序为 abc,逆序为 cba,不相同。 输入长度为 n 的串 S,求 S 的最长双回文子串 T,即可将 T 分为两部分 X, Y (|X|, |Y| 1) 且 X 和 Y 都是回文串。  $n \leq 10^6$  。

## Luogu4555

#### 题面

顺序和逆序读起来完全一样的串叫做回文串。比如 acbca 是回文串,而 abc 不是: abc 的顺序为 abc,逆序为 cba,不相同。 输入长度为 n 的串 S,求 S 的最长双回文子串 T,即可将 T 分为两部分 X, Y (|X|, |Y| 1) 且 X 和 Y 都是回文串。  $n \le 10^6$  。

枚举划分点即可。



## 后缀数组

后缀数组存储后缀按字典序排序后的结果。 常见的有 *nlogn* 的倍增,以及线性的 SA-IS。



# 倍增后缀数组

大家都会



例题

## 后缀数组

### LOJ2377

给定一个长度为 n 的字符串 S ,令  $T_i$  表示它从第 i 个字符开始的后缀,求:

$$\sum_{1 \le i < j \le n} \operatorname{len}(T_i) + \operatorname{len}(T_j) - 2\operatorname{lcp}(T_i, T_j)$$

 $2 \leq n \leq 500000$ 

例题

## 后缀数组

### LOJ2377

给定一个长度为 n 的字符串 S ,令  $T_i$  表示它从第 i 个字符开始的后缀,求:

$$\sum_{1 \le i < j \le n} \operatorname{len}(T_i) + \operatorname{len}(T_j) - 2\operatorname{lcp}(T_i, T_j)$$

 $2 \leq n \leq 500000$ 

简单题

# 后缀数组

#### LOJ2083

如果一个字符串可以被拆分为 AABB 的形式,其中 A 和 B 是任意非空字符串,则 我们称该字符串的这种拆分是优秀的。

现在有 T 组询问,每组询问给出一个长度为 n 的字符串 S,求出在它所有子串的所有拆分方式中,优秀拆分的总个数。

其中出现在不同位置的相同子串,我们认为是不同的子串,它们的优秀拆分均会被记入答案。

 $1 \le T \le 10, \ n \le 30000$ 

# 后缀数组

#### LOJ2083

如果一个字符串可以被拆分为 AABB 的形式,其中 A 和 B 是任意非空字符串,则我们称该字符串的这种拆分是优秀的。

现在有 T 组询问,每组询问给出一个长度为 n 的字符串 S,求出在它所有子串的所有拆分方式中,优秀拆分的总个数。

其中出现在不同位置的相同子串,我们认为是不同的子串,它们的优秀拆分均会被记入答案。

 $1 \le T \le 10, \ n \le 30000$ 

先考虑求出以 i 结尾的 AA 的数量  $f_i$  以及以 i 开头的 BB 的数量  $g_i$ 。答案就是  $\sum_i f_i g_{i+1}$ 

可以枚举长度后求 Icp。由于有调和级数,复杂度为  $O(n \log n)$ 。

例题

## 后缀数组

### LOJ2133

给定串 S, 求  $\exists i \in [0,n)$  求有多少对后缀满足  $Len(lcp) \geq i$ , 以及满足条件的两个后缀的权值  $a_i$  乘积的最大值。

$$n \le 300000, |a_i| \le 10^9$$

例题

## 后缀数组

### LOJ2133

给定串 S,求  $\exists i \in [0, n)$  求有多少对后缀满足  $Len(lcp) \geq i$ ,以及满足条件的两个后缀的权值  $a_i$  乘积的最大值。

 $n \le 300000, |a_i| \le 10^9$ 

处理出后缀数组后排序维护一个单调栈即可。

### **PAM**

每个本质相同的回文串用一个节点表示。每个节点的父亲为最长回文 border, nxt 数组记录增加一个字符之后的节点。

性质:本质不同回文串个数为 O(n)。

参考代码连接



## Luogu4287

#### 题面

记字符串 w 的倒置为  $w^R$ 。例如  $(abcd)^R=dcba$ , $(abba)^R=abba$ 。 对字符串 x,如果 x 满足  $x^R=x$ ,则称之为回文;例如 abba 是一个回文,而 abed 不是。

如果 x 能够写成的  $ww^Rww^R$  形式,则称它是一个"双倍回文"。换句话说,若要 x 是双倍回文,它的长度必须是 4 的倍数,而且 x, x 的前半部分,x 的后半部分都要是回文。例如 abbaabba 是一个双倍回文,而 abaaba 不是,因为它的长度不是 4 的倍数。

- x 的子串是指在 x 中连续的一段字符所组成的字符串。例如 be 是 abed 的子串,而 ac 不是。
- x 的回文子串,就是指满足回文性质的 x 的子串。
- x 的双倍回文子串,就是指满足双倍回文性质的 x 的子串。

你的任务是,对于给定的字符串,计算它的最长双倍回文子串的长度。

 $n \le 10^{6}$  o

### Luogu4287

#### 题面

记字符串 w 的倒置为  $w^R$ 。例如  $(abcd)^R = dcba$ , $(abba)^R = abba$ 。 对字符串 x,如果 x 满足  $x^R = x$ ,则称之为回文;例如 abba 是一个回文,而 abed 不是。

如果 x 能够写成的  $ww^Rww^R$  形式,则称它是一个"双倍回文"。换句话说,若要 x 是双倍回文,它的长度必须是 4 的倍数,而且 x, x 的前半部分,x 的后半部分都要是回文。例如 abbaabba 是一个双倍回文,而 abaaba 不是,因为它的长度不是 4 的倍数。

- x 的子串是指在 x 中连续的一段字符所组成的字符串。例如 be 是 abed 的子串,而 ac 不是。
- x 的回文子串,就是指满足回文性质的 x 的子串。
- x 的双倍回文子串,就是指满足双倍回文性质的 x 的子串。

你的任务是,对于给定的字符串,计算它的最长双倍回文子串的长度。

 $n \leq 10^6$  o

用 PAM 维护一下长度为 ||s|/2| 的串所在节点即可。



## K-palindrome String

#### 题面

定义 s 是 k-回文串当且仅当 s 回文并且 s 的长度为  $\lfloor |s|/2 \rfloor$  的前缀和后缀均为 (k-1)-回文串。同时规定所有串都是 0-回文串。 定义一个串 s 的回文度为最大的 k ,满足 s 是 k-回文串。 输入一个串 s ,求 s 的所有前缀的回文度。  $|s| \le 5 \times 10^6$  。

## K-palindrome String

#### 题面

定义 s 是 k-回文串当且仅当 s 回文并且 s 的长度为  $\lfloor |s|/2 \rfloor$  的前缀和后缀均为 (k-1)-回文串。同时规定所有串都是 0-回文串。 定义一个串 s 的回文度为最大的 k ,满足 s 是 k-回文串。 输入一个串 s ,求 s 的所有前缀的回文度。  $|s| \le 5 \times 10^6$  。

一样用 PAM 维护一下长度为  $\lfloor |s|/2 \rfloor$  的串所在节点即可。

### Luogu4762

#### 题面

初始有一个空串,利用下面的操作构造给定串 S。

- 串开头或末尾加一个字符
- ■串开头或末尾加一个该串的逆串

求最小化操作数,字符集为  $\{A, T, C, G\}$ 。  $n \leq 10^6$ 。

### Luogu4762

#### 题面

初始有一个空串,利用下面的操作构造给定串 S。

- 串开头或末尾加一个字符
- 串开头或末尾加一个该串的逆串

求最小化操作数,字符集为  $\{A, T, C, G\}$ 。  $n \leq 10^6$ 。

一样维护指针后在 PAM 上 dp 即可。转移分为从 border 处转移以及向 nxt 转移。



MP Trie AC 自动机 Manacher 后缀数组 PAM **后缀自动机** 后缀平衡树 广义后缀自动机 一些简单, ○○○○○ ○○ ○○ ○○ ○○ ○○ ○○○ ○○○ ○○○ ○○○

### 后缀自动机的定义

对于所有 endpos 集合相同的子串将其压缩到同一个点上。

或者:后缀树上压缩二度点。

同时每个节点会有一个 link 指向其后缀中第一个 endpos 集合变大的节点以及  $\Sigma$  个

nxt 指向加入一个字符后这些子串中最长的那个会转移到哪个节点上。



## 后缀自动机

字符串 s 的 SAM 是一个接受 s 的所有后缀的最小 DFA(确定性有限自动机或确定性有限状态自动机)。换句话说:

- SAM 是一张有向无环图。结点被称作状态,边被称作状态间的转移。
- 图存在一个源点 to, 称作初始状态,其它各结点均可从 to 出发到达。
- 每个转移都标有一些字母。从一个结点出发的所有转移均不同。 存在一个或多个终止状态。如果我们从初始状态 t<sub>0</sub> 出发,最终转移到了一个终 止状态,则路径上的所有转移连接起来一定是字符串 s 的一个后缀。s 的每个 后缀均可用一条从 t<sub>0</sub> 到某个终止状态的路径构成。
- 在所有满足上述条件的自动机中,SAM 的结点数是最少的。



## 后缀自动机的构建

点击就送代码。

增量法:维护 last 表示当前整个串所在节点。加入字符 x 时将 last 的一部分不存在 nxt[x] 祖先定位到新节点 (新节点为当前新的整个串)。

对于那些存在 nxt[x] 的祖先,找到最下面的祖先,称之为 p,以及 nxt[p] 称为 q。 如果 len[q]=len[p]+1,那么在新加入 x 后会恰好给 q 加入一个 endpos。

否则加入的 x 与 p 形成的这个串会让 q 分裂为一个长度为 len[p]+1 的串 t 以及长度为 len[q] 的串 q'。将原先 nxt[p]=q 的点全部改成 t 就行。

## 后缀自动机

SAM 最简单、也最重要的性质是,它包含关于字符串 s 的所有子串的信息。任意从 初始状态  $t_0$  开始的路径,如果我们将转移路径上的标号写下来,都会形成 s 的一个 子串。反之每个 s 的子串对应从  $t_0$  开始的某条路径。

为了简化表达,我们称子串对应一条路径(从 to 开始、由一些标号构成这个子串)。 反过来,我们说任意一条路径对应它的标号构成的字符串。

例题

# 后缀自动机

### 简单题

给出一个长度为 N 的字符串,对于每个长度 L,求所有长度为 L 的子串中出现次数最多的串出现了多少次。

数据范围: 200000。



## 后缀平衡树

支持在线向前加入字符并维护后缀顺序。 可以通过 Treap 或替罪羊树基于比较做到  $O(n\log^2)$ 。 或者将其映射到实数做到  $O(n\log)$ 。



## 后缀平衡树

#### Luogu6164

给你一个字符串 init, 要求你支持三个操作:

- 1 在当前字符串的后面插入若干个字符。
- 2 在当前字符串的后面删除若干个字符。
- **3** 询问字符串 *s* 在当前字符串中出现了几次(作为连续子串)?

你必须在线支持这些操作。

数据字符串变化长度以及初始长度和  $\leq 8 \times 10^5$ ,询问次数  $\leq 10^5$ ,询问总长度  $< 3 \times 10^6$ 

### 后缀平衡树

#### Luogu6164

给你一个字符串 init, 要求你支持三个操作:

- 1 在当前字符串的后面插入若干个字符。
- 2 在当前字符串的后面删除若干个字符。
- **3** 询问字符串 s 在当前字符串中出现了几次(作为连续子串)?

你必须在线支持这些操作。

数据字符串变化长度以及初始长度和  $\leq 8 \times 10^5$ ,询问次数  $\leq 10^5$ ,询问总长度  $< 3 \times 10^6$ 

板子题



## 广义后缀自动机

广义后缀自动机将后缀自动机整合到字典树中来解决对于多个字符串的子串问题。



### 常见的伪广义后缀自动机

- 通过用特殊符号将多个串直接连接后,再建立 SAM。
- 对每个串,重复在同一个 SAM 上进行建立,每次建立前,将 last 指针置零。

这些方法实现方式简单,而且在面对题目时通常可以达到和广义后缀自动机一样的正确性,但其时间复杂度均较为危险。



## 广义后缀自动机的离线构造

用所有模式串建出一颗 Trie 树,对其进行 dfs/bfs 遍历构建 SAM, insert 时使 last 为它在 Trie 树上的父亲,其余和普通 SAM 一样。 需要注意如果是直接给的一颗 Trie, 那么 dfs 可以被卡。



# 广义后缀自动机的在线构造

多加几个特判即可。



例题

# 广义后缀自动机

#### CF666E

给出主串 S 以及 m 个字符串 T[1..m] 。有若干次询问,每次查询 S 的子串  $S[p_l..p_r]$  在 T[l..r] 中的哪个串  $T_i$  里的出现次数最多,输出 i 以及出现次数,有多解则取最靠前的那一个。

例颢

# 广义后缀自动机

#### CF666E

给出主串 S 以及 m 个字符串 T[1..m] 。有若干次询问,每次查询 S 的子串  $S[p_l..p_r]$  在 T[l..r] 中的哪个串  $T_i$  里的出现次数最多,输出 i 以及出现次数,有多解则取最靠前的那一个。

先把所有字符串都插入到广义 SAM 中,对于每个节点开一颗下标为 [1,m] 的动态 开点线段树维护 siz (注意插入 S 时就不要在线段树上进行修改操作了)。由于 siz 的维护是统计子树和,所以插入结束后要在 parent 树上跑一下线段树合并。 查询时先在 parent 树上倍增找到包含子串  $S[p_l,p_r]$  的等价类状态节点,然后在该点的线段树上查询区间 [l,r] 中的最大值,顺便维护下最大值所处位置即可。

#### LOJ3089

给定一只由数字和 . 构成的字符串 s。给定 m 个特殊串  $t_1 \sim t_m$  ,  $t_i$  的权值为  $v_i$ 。 需要在 s 中为 . 的位置上填入数字,一种填入方案的价值定义为:

$$\sqrt[c]{\prod_{i=1}^c w_i}$$

其中 W 表示在该填入方案中, 出现过的特殊串的价值的可重集合, 其大小为 c。 每个位置填入的数字任意,最大化填入方案的价值,并输出任意一个方案。 设  $s = \sum_{i=1}^{m} |S_i|$ 。

$$1 \le n, m, s \le 1501, 1 \le V_i \le 10^9$$
 o

#### LOJ3089

给定一只由数字和 . 构成的字符串 s。给定 m 个特殊串  $t_1 \sim t_m$ ,  $t_i$  的权值为  $v_i$ 。需要在 s 中为 . 的位置上填入数字,一种填入方案的价值定义为:

$$\sqrt[c]{\prod_{i=1}^{c} w_i}$$

其中 W 表示在该填入方案中,出现过的特殊串的价值的可重集合,其大小为 c。每个位置填入的数字任意,最大化填入方案的价值,并输出任意一个方案。设  $s=\sum_{i=1}^m |S_i|$ 。

 $1 \le n, m, s \le 1501, 1 \le V_i \le 10^9$  o

取对数后可以变成分数规划,AC 自动机上 dp 即可。

#### CF1313E

给定三个串 a, b, s,其中 a, b 长度为 n,s 长度为 m,求出四元组 (l1, r1, l2, r2) 的个数,满足:

- [*l*1, *r*1] 和 [*l*2, *r*2] 的交集非空。
- lacksquare a 中位置 l1 到 r1 组成的子串与 b 中位置 l2 到 r2 组成的子串拼起来恰好是 s0.

 $n \leq 10^5$  o



#### CF1313E

给定三个串 a, b, s, 其中 a, b 长度为 n, s 长度为 m, 求出四元组 (l1, r1, l2, r2) 的个数,满足:

- [l1, r1] 和 [l2, r2] 的交集非空。
- a 中位置 l1 到 r1 组成的子串与 b 中位置 l2 到 r2 组成的子串拼起来恰好是 s。  $n \leq 10^5$ 。

先 exkmp 求出 a 每个位置向后和 b 每个位置向前最长延伸长度。剩下的可以树状数组解决。

https://uoj.ac/problem/172



https://uoj.ac/problem/172 由于 border 构成 log 个等差数列,我们可以对于每个等差数列跑一个同余最短路。 切换模数的时候也可以用一个同余最短路。



贾樟柯在《山河故人》里说,「生活就是重复」。在生活中,人们总是喜欢重复自己做过的事情。语言就是一个很经典的例子。

比如,我们在表示疑问时,总不满足于使用一个问号「?」; 使用一连串的问号「????」总是显得比较有力。

在表示抱歉时,一句「对不起」总显得不够情愿;连着表示「对不起对不起」才足 够表达自己的真诚。

A 国就是一个喜欢重复的国家。在这个国家中,一个基本句子可以用一个长度恰好为m的小写字母字符串表示。为了表达自己对重复的喜爱,A 国的人们总喜欢把自己想要表达的句子重复无限多次。

有时,这样的重复是充满意义的。A 国的人们把一个字典序小于给定的字符串 s,且长度和 s 相同的小写字母字符串称为一个有意义的语义片段。他们想知道,有多少个不同的基本句子(即长度恰好为 m 的小写字母字符串)在经过无限重复后,可以从中找出至少一个有意义的语义片段?

 $n, m \leq 2000$  •

首先补集转化。考虑如何判断一个字符串是否合法。对于与 s 的 lcp,可以使用 lcp,不以使用 lcp,一旦比 lcp,证此任何字符更小就 lcp,如此 lcp,可以使用

考虑使用 dp 来做这个过程。由于是循环,我们考虑在充分长之后沿着字符串走在 s 的 kmp 上的节点会有循环节。令  $f_{i,j,k,0/1}$  表示从 i 号节点出发,当前走了 j 步到达 k 号节点,中间是否已经合法的方案数。最后统计  $f_{i,|s|,i}$  的答案即可。复杂度  $O(n^3)$ 。发现环可以分为经过根节点和不经过根节点的两种。不经过根节点可以直接判断 (转移唯一),经过根节点可以枚举起始节点和第一次转移到根节点前走的距离,预处理出  $f_{i,x}$  表示从根出发走 i 步到达 x 的方案数。

最后快速算出第一次转移到根节点前的方案数,因为自动机一直不经过根节点前走的路径是唯一的。

使用多项式求逆好像可以做到  $O(m \log m + n)$ 。

